UNIWERSYTET GDAŃSKI
Wydział Matematyki, Fizyki i Informatyki

Michał Jakóbowski
nr albumu: 240 336

Generowanie treści przy pomocy rekurencyjnych sieci neuronowych

Praca magisterska na kierunku:
INFORMATYKA
Promotor:
dr Włodzimierz Bzyl

Gdańsk 2017

Streszczenie

W pracy zostało opisane działanie oraz wybrane możliwości wykorzystania modelu rekurencyjnych sieci neuronowych autorstwa Andreja Karpathy'ego, udoskonalonego przez Justina Johnsona.[1] Model ten nosi nazwę Torch-rnn i jego kod źródłowy jest dostępny na platformie GitHub. Jest on realizacją wielopoziomowej rekurencyjnej sieci neuronowej typu Long Short-Term Memory (LSTM) polegającą na generowaniu treści (sekwencji znaków) na podstawie wcześniej zgromadzonej bazy danych treningowych.

W pierwszym rozdziale omówiono zagadnienie sieci neuronowych, zaczynając od fundamentów jakimi była koncepcja neuronu McCullocha-Pittsa poprzez współczesne sieci neuronowe, a kończąc na rekurencyjnych sieciach neuronowych typu LSTM wykorzystywanych w omawianym modelu. W dalszej części skupiono się na przedstawieniu środowiska programistycznego Torch-RNN, szczegółowo opisano sposób instalacji wszystkich wymaganych bibliotek oraz zależności na środowisku sprzętowym udostępnionym przez Instytut Informatyki Uniwersytetu Gdańskiego. W tym miejscu autor pragnie podziękować Panu mgr Krzysztofowi Sikorskiemu oraz mgr inż. Stanisławowi Tuszyńskiemu za udostępnienie serwerów obliczeniowych do przeprowadzenia badań.

Meritum pracy zostało zawarte w rozdziale opisującym eksperymenty związane z procesem treningowym omawianej sieci neuronowej. Przedstawiono tam metodykę prowadzenia eksperymentów, sposób interpretacji wyników oraz przede wszystkim efekty wykorzystania tychże sieci. Eksperymenty dotyczyły generowania tekstów przypominających dzieła literackie Willama Szekspira (pokazano dramat szekspirowski) oraz Henryka Sienkiewicza (powieść w języku polskim), autor spróbował również wykorzystać sieć neuronową do wygenerowania sekwencji nut zapisanych w formie tekstowej, następnie przekształcił ową sekwencję na plik w formacie midi. Dodatkowo zaprezentowana została obsługa języka znaczników platformy Wikimedia (popularnonaukowe artykuły z dziedziny Fizyki) oraz generowanie kodu źródłowego w obiektowym języku programistycznym Java. Na koniec porównano czas dzia-

łania procesu treningowego w zależności od wybranej architektury sprzętowej oraz stopnia skomplikowania wybranego modelu sieci neuronowej.

W podsumowaniu autor dokonuje oceny efektów wykonanych eksperymentów, omawia wyciągnięte w ten sposób wnioski, a następnie przedstawia przewidywania na przyszłość związane z możliwościami jakie dają rekurencyjne sieci neuronowe typu LSTM.

Słowa kluczowe

Rekurencyjne sieci neuronowe, LSTM, torch, character level language, język naturalny, torch-rnn, CUDA, python, bash

Spis treści

Wprowadzenie

Rozwinięty mózg jest cechą która wyróżnia nas, ludzi spośród innych przedstawicieli świata zwierząt. Mimo, że zwierzęta często bywają od nas większe i silniejsze, to jednak pewne własności naszego mózgu pozwoliły nam osiągnąć nad nimi przewagę. Mowa tu o szeroko rozumianej inteligencji, którą udało nam się rozwinąć w drodze ewolucji. Ewolucja jednak jest procesem rozciągniętym na bardzo długi okres czasu, a ludzkość chcąca się rozwijać w znacznie szybszym tempie wpadła na pomysł wytworzenia sztucznej inteligencji, która to w zamierzeniu ma osiągnąć nasz poziom. Z czasem być może go prześcigając.

Prowadzić to może do trudnych do przewidzenia konsekwencji, jednak nie tym chciałbym zająć się w tej pracy. Opiszę natomiast techniczne podstawy tego zagadnienia, skupiając się na jednej z cech jaką moim zdaniem powinna posiadać sztuczna inteligencja. Jest to umiejętność tworzenia tekstu (pisania). To między innymi dzięki tej umiejętności ludzkość mogła osiągnąć obecny poziom rozwoju, przekazując teksty z pokolenia na pokolenie mogliśmy kumulować nasze doświadczenia oraz umiejętności.

Moją motywacją do napisanie tej pracy stał się cytat pozostawiony przez jednego z pionierów zagadnienia sztucznej inteligencji jakim był Alan Turing. W roku 1950 zaproponował on pomysł na powołanie do życia sztucznej inteligencji. Chodzi tu o propozycję tak zwanego "umysłu dziecka", którą opisał następująco:

Może zamiast dążyć do wytworzenia programu udającego umysł dorosłego, spróbować raczej wyprodukować program udający umysł dziecka? Poddawszy go stosownej edukacji, uzyskalibyśmy umysł dorosłego.[2]

Ten prosty w swych założeniach pomysł zdaje się przyświecać zagadnieniu sieci neuronowych. Są to składające się z wielu sztucznych neuronów sieci, które w swych założeniach mają imitować działanie prawdziwego mózgu. Owe symulatory modeli matematycznych analizując pewien zbiór danych posiadają zdolność do przyswajania pewnych zależności. Dzięki nim można

próbować rozwiązywać problemy, których nie udałoby się rozwiązać w sposób algorytmiczny (lub wymagałoby to dużych zasobów).

Takim problemem jest właśnie omawiane w tej pracy generowanie tekstu. Do swoich eksperymentów, których przebieg szczegółowo opiszę w tej pracy, wykorzystałem implementację rekurencyjnych sieci neuronowych zaproponowaną przez Andreja Karpathy'ego z Uniwersytetu Stanforda.[3] Większość prac była prowadzona na środowisku sprzętowym udostępnionym przez Instytut Informatyki Uniwersytetu Gdańskiego.

ROZDZIAŁ 1

Rekurencyjne sieci neuronowe (LSTM)

1.1. Koncept neuronu

Sieciami neuronowymi określa się symulatory (programowe lub sprzętowe) modeli matematycznych realizujące pseudorównoległe przetwarzanie informacji, składające się z wielu wzajemnie połączonych neuronów i naśladujące działanie biologicznych struktur mózgowych.[4]

Zagadnienie to budzi coraz większe zainteresowanie na całym świecie. Z pewnością można je zakwalifikować jako dziedzinę nauk technicznych, jednak warto tutaj wspomnieć o źródłach z których wywodzi się ta nowoczesna technika. Podstaw konceptu sieci neuronowych należy się doszukiwać w odkryciach biologów którzy to śledzą tajemnice ludzkiego mózgu. Wielu z nich doczekało się najważniejszej nagrody w świecie nauki - czyli nagrody Nobla. Poniżej zaprezentowano tabelę z najważniejszymi odkryciami z dziedziny neurologii wraz z datą oraz nazwiskiem odkrywcy:

Rok	*Imię i nazwisko*	*Odkrycie*
1904	Iwan Pawłow	Odruch warunkowy klasyczny
1906	Santiago Ramon y Cajal i Camillo Golgi	Struktura układu nerwowego
1924	Willem Einthoven	Biopotencjał tkanek
1932	Sir Charles Scott Sherrington i Edgar Douglas Adrian	Opis funkcji neuronów
1961	Georg von Bekesy	Model percepcji słuchowej
1963	Alan Lloyd Hodgkin i Andrew Fielding Huxley	Model propagacji sygnału w aksonie
1963	Sir John Carew Eccles	Model synapsy
1967	Ragnar Granit, Haldan Keffer Hartline i George Wald	Opis procesu widzenia w oku
1970	Sir Bernard Katz	Opis potencjału czynnościowego, czyli zasady "wszystko albo nic"
1904	David H. Hubel i Torsten N. Wiesel	Opis procesu przekazywania informacji w układzie wzrokowym
1986	Nikolaas Tinbergen i Konrad Lorenz	Model celowego zachowania

Tabela 1.1. Wybrani zdobywcy nagrody Nobla dziedziny neurologii

Źródło: The Nobel Foundation - nobleprize.org

Z pewnością warto pamiętać o tych odkryciach. W dalszej części jednak skupmy się na informatycznych zagadnieniach dotyczących sieci neuronowych. Pierwszy matematyczny opis komórki nerwowej wraz z powiązaniem tego problemu z przetwarzaniem danych został dokonany przez Warrena McCullocka i Waltera Pittsa w 1943 roku. Model zaproponowany przez nich

stał się budulcem podstawowym budulcem sieci neuronowej typu perceptron. Nuron tego typu posiada wiele wejść oraz jedno wyjście. Każdemu z wejść przyporządkowana jest liczba rzeczywista stanowiąca wagę. Wartością wyjściową jest wartości funkcji aktywacji obliczona na sumie ważonej wartości wejściowych pomnożonych przez wagi. Poniżej schemat neuronu McCullocha-Pittsa:

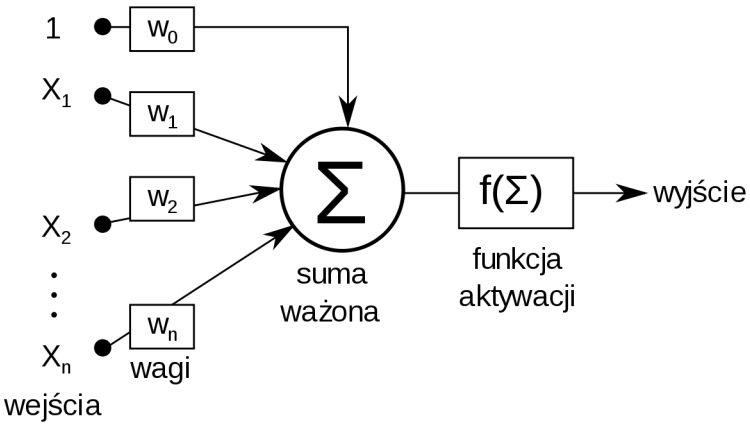

Rysunek 1.1. Schemat neuronu McCullocha-Pittsa

Źródło: Portal researchgate.net

1.2. Wielowarstwowe sieci neuronowe

Sieć neuronowa składa się z wielu neuronów (opisanych w poprzedniej sekcji) połączonych w taki sposób aby wyjście jednego mogło być wejściem innego. Poniżej przykład schematu prostej sieci neuronowej:

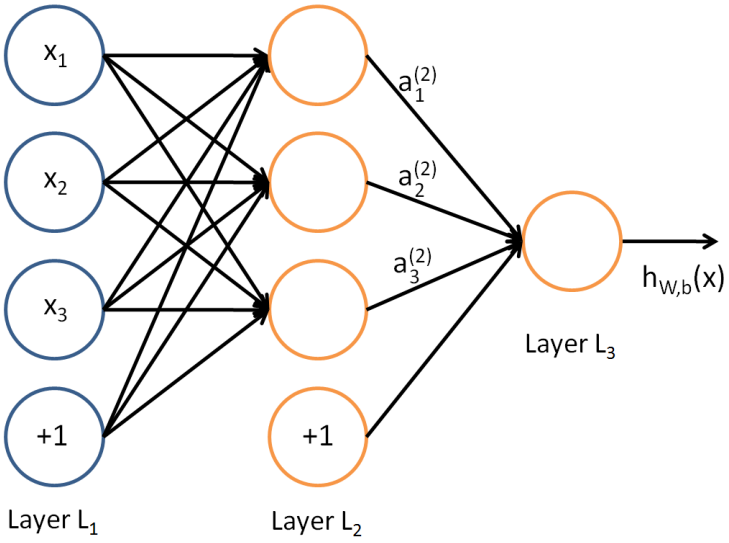

Rysunek 1.2. Schemat warstwowej sieci neuronowej

Źródło: stanford.edu

Na tej ilustracji użyto kółek do oznaczania wejść do sieci. Okręgi oznaczone ”+1” nazywamy jednostami wyrównania (z ang. *Bias units*) i pozwalają one sterować funkcją aktywacyjną (w zależności od wartości jednostek wyrównania możemy przesunąć funkcję aktywacyjną w lewo, bądź w prawo). Warstwa znajdująca się na ilustracji po lewej stronie nazywana jest warstwą wejściową (*input layer*), ta będąca po prawej nazywana jest wyjściową (*output layer*, na tym przykładzie posiada tylko jeden węzeł). Środkowa warstwa nazywana jest warstwą ukrytą (*hidden layer*), ponieważ jej wartości nie możemy zaobserwować na zbiorze treningowym. Można zatem powiedzieć, że na przykładzie zaprezentowano sieć neuronową posiadającą 3 jednostki wejściowe (nie wliczamy jednostek sterujących), 3 ukrte warstwy oraz pojedyńczą jednostkę wyjściową. [5]

1.3. Rekurencyjne sieci neuronowe

Umysł ludzki nie rozpoczyna swojego myślenia od podstaw w każdej sekundzie. Czytając jakiś tekst nie zastanawiamy się nad sensem każdego ze słów oddzielnie, lecz staramy się wnioskować z kontekstu danego zdania, całego tekstu czy też całej wiedzy którą posiadamy. Tradycyjne sieci neuronowe nie posiadają takiej możliwości, nie są w stanie odwoływać się do wcześniej zdobytej wiedzy. Problem ten rozwiązują rekurencyjne sieci neuronowe. Różnią się one od tradycyjnych sieci tym, że posiadają wewnątrz swojej architektury pętle pozwalające na zachowanie pewnych informacji.

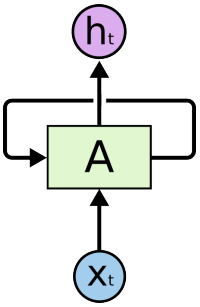

Rysunek 1.3. Fragment prostej rekurencyjnej sieci neuronowej

Źródło: colah.github.io

Na powyższym diagramie widzimy fragment rekurencyjnej sieci neuronowej. Węzeł *A* otrzymuje dane wejściowe z *Xt* i zwraca wartość *Ht*. Pętla natomiast umożliwia przekazywanie informacji z jednego etapu do następnego. Innymi słowy, taką sieć można traktować jako łańcuch wielu kopii tej samej sieci, każda przekazuje wiadomość kolejnej. Między innymi to właśnie ta sekwencyjna natura rekurencyjnych sieci neuronowych pozowli wykorzystać je do eksperymentów z analizowaniem i generowaniem treści które to zostaną opisane w stosownym rozdziale.[6]

1.4. Sieci Long Short-Term Memory (LSTM)

LSTM jest to specjalny rodzaj rekurencyjnych sieci neuronowych zdolny do przyswajania pewnych zależności na długi okres czasu. Zostały opracowane przez Seppa Hochreitera i Jürgen Schmidhuber w 1997 roku i od tamtej pory zyskały dużą popularność. Stosowane są przez największe firmy inwestujące w branżę sztucznej inteligencji typu Google, Microsoft czy Apple.[7]

Jak wspomniane zostało w poprzedniej sekcji - wszystkie rekurencyjne sieci neuronowe są sekwencją składającą się z powtarzających się modułów. Cechą charakterystyczą sieci LSTM jest to, że potrafią one przekazywać (zapamiętywać) informacje w głąb owego łańcucha modułów.

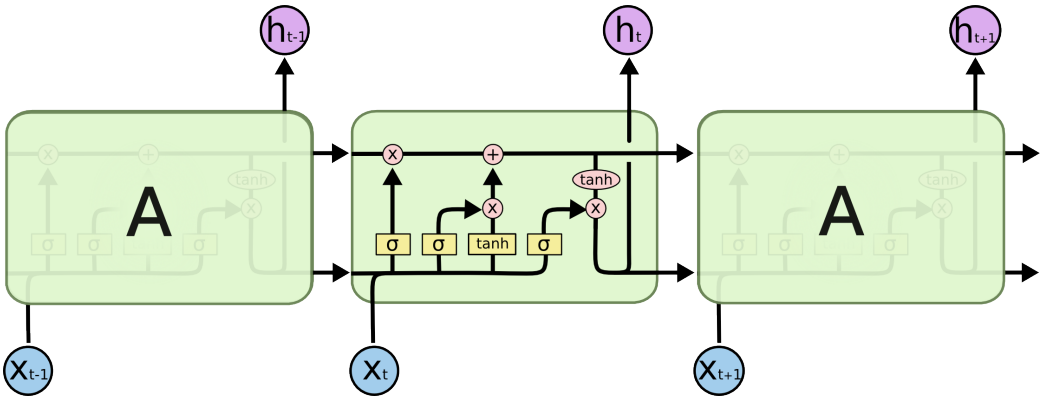

Rysunek 1.4. Schemat powtarzającego się modułu sieci LSTM

Źródło: colah.github.io

Na powyższym schemacie każda z linii przenosi wektor z wyjścia jednego węzła do wejścia innych. Żółte prostokąty symbolizują warstwy sieci neuronowej, różowe kółka to operacje punktowe (takie jak np dodawanie wektorów), połączenia linii to konkatenacja wektorów, linie rozłączne oznaczają kopiowanie wektorów.

Główna idea sieci LSTM zawiera się w poziomej linii która jest na górze diagramu. Jest to stan komórki odpowiedzialny właśnie za przenoszenie

informacji w głąb sekwencji powtarzających się modułów. Jak widać stan ten może zostać jedynie drobnie zmodyfikowany w trakcie działania sieci. Za jego modyfikacje odpowiadają bramki oznaczone na diagramie literą , które to decydują w jakim stopniu dany komponent będzie miał wpływ na stan komórki. Wartości te wachają się od 0 (brak wpływu na stan komórki) do 1 (duży wpływ na stan komórki).[6]

To właśnie na podstawie tego rodzaju sieci neuronowych przedstawione zostanie zagadnienie generowania treści.

ROZDZIAŁ 2

Środowisko torch-rnn na serwerze obliczeniowym Instytutu Informatyki

Zanim jednak będzie można przejść do samego procesu treningowego należy poprawnie skonfigurować środowisko w którym rekurencyjne sieci neuronowe typu LSTM będą działać. W pracy wykorzystano implementację zaproponowaną przez Andreja Karpathego z Uniwersytetu Stanforda, a następnie udoskonaloną przez Justina Johnsona (również doktoranta Stanfordzkiej uczelni). Projekt jest dosępny na platformie Github. Zawiera on zarówno implementację omawianych sieci oraz informację na temat zależności (z ang. *dependencies*) niezbędnych do poprawnego działania sieci.

Na potrzeby danych ekserymentów skorzystano z trzech konfiguracji sprzętowych udostępnionych przez Instytut Informatyki Uniwersytetu Gdańskiego. Większość prac była przeprowadzana w trybie zdalnym z użyciem protokołu Secure Shell.

CPU	*Karta graficzna*	*System*
Intel® Xeon® Processor 32-cores 3.60 GHz	-	Ubuntu 16.04.2 LTS
Intel® Core™ i5-2410M CPU @ 2.30GHz × 4	GeForce GT 520M	Ubuntu 16.04.2 LTS
Intel i7-7700 3.60GHz × 4	GeForce GTX 960	Xubuntu 16.04.1

Tabela 2.1. Architektura sprzętowa wykorzystywana do eksperymentów

Źródło: opracowanie własne

2.1. Instalacja bibliotek pomocniczych

Pierwszym krokiem przygotowującym środowisko jest sprawdzenie czy mamy zapewniony w naszym systemie dostęp do narzędzia Cmake. Narzędzie to służy do budowania oraz testowania pakietów oprogramowania w systemie. Jest ono konieczne do zainstalowania środowiska programistycznego torch. Podobna sytuacja jest z pakietem OpenBLAS zapewniającym podstawowe narzędzia służące do obliczeń na wektorach oraz macierzach (a to głównie z tego rodzaju obliczeń korzystają sieci neuronowe). Oba te narzędzia w systemie Ubuntu można zainstalować z poziomu terminala (przy założeniu, że nasz użytkownik jest zapisany na liście sudoers). Wspomniane narzędzia instalujemy w następujący sposób:

```
#OpenBLAS:
sudo apt-get install libopenblas-dev
#Cmake:
sudo apt-get install build-essential
wget http://www.cmake.org/files/v3.5/cmake-3.5.2.tar.gz
tar xf cmake-3.5.2.tar.gz
cd cmake-3.5.2
./configure
make
sudo make install
```

Pamiętać również należy o sprawdzeniu poprawności zmiennych środowiskowych prowadzących do biblioteki OpenBLAS, w razie konieczności trzeba jest ustawić w następujący sposób:

```
export CMAKE_LIBRARY_PATH=/opt/OpenBLAS/lib
export LD_LIBRARY_PATH=/opt/OpenBLAS/lib
```

2.2. Preprocessing danych

Rekurencyjne sieci neuronowe typu LSTM pełnię swoich możliwości są w stanie pokazać jedynie, gdy będą mogły działać na odpowiednio bogatym w

treść zbiorze danych treningowych. Aby taki zbiór uzyskać zgromadzone dane należy poddać procesowi przygotowawczemu. Do przeprowadzenia procesu przygotowawczego potrzebujemy bibliotek wyspecjalizowanych w obsłudze dużych zbiorów danych. Do instalacji owych bibliotek niezbędny okazuje się być kompilator języka Python (najlepiej w wersji 2.7), można go zainstalować z oficjalnego repozytorium systemu Ubuntu:

```
sudo add-apt-repository ppa:fkrull/deadsnakes
sudo apt-get update
sudo apt-get install python2.7
```

Kompilator języka Python pozwoli nam zainstalować w pamięci wirtualnej systemu następujace (wymagane) pakiety:

- Cython - jest to kompilator pozwalający na łączenie ze sobą (wstrzykiwanie) oraz kompilowanie kodu, zarówno Pythona jak i języka C.
- Numpy - pakiet funkcji matematycznych pozwalający na obsługę macierzy i tablic N-tego poziomu, oraz na integrację ze sobą języka programowania C z Fortranem.
- Argparse - moduł ułatwiający przekazywanie argumentów wewnątrz fukncji, dzięki niemu w prosty sposób można stworzyć unterfejs użytkownika na poziomie linii komend.
- H5py - pakiet zapewniający obsługę binarnego formatu danych HDF5. To właśnie w tym formacie tworzony jest zbiór treningowy sieci neuronowych będących tematem pracy.
- Six - pakiet pozwalający na uzyskanie kompatybilności kodu między różnymi wersjami języka Python (głównie mowa tu o różnicach między wersjami języka 2 i 3).

Z poziomu Terminala instalacja wygląda następująco:

```
virtualenv .env      # Utworzenie środowiska w pamięci wirtualnej
source .env/bin/activate # Aktywowanie tegoż środowiska
pip install -r requirements.txt # Instalacja omówionych pakietów
deactivate  # Opuszczenie środowiska wirtualnego
```

2.3. Framework Torch

Kolejnym krokiem jest przygotowanie środowiska programistycznego LUA z frameworkiem Torch, to właśnie w tym języku programowania zostało zaimplementowana rekurencyjna sieć neuronowa typu LSTM na której przeprowadzone zostaną eksperymenty z systemem generowania treści.

Proces instalacji frameworka sprowadza się do pobrania repozytorium z platformy GitHub oraz wykonania zawartych w nim skryptów, które to w efekcie doprowadzą do zaintalowania kolejnych wymaganych narzędzi, takich jak LuaJIT(kompilator skryptowego języka Lua), czy LuaRocks(menadżer pakietów języka Lua). Po wszystkim należy odświeżyć zmienne środowiskowe systemu linux tak aby zapisane w nich ścieżki dostępu zostały zapisane: [8]

```
git clone https://github.com/torch/distro.git ~/torch --recursive
cd ~/torch; bash install-deps;
./install.sh
#Po instlacji wczytujemy zmienne środowiskowe:
source ~/.bashrc
```

Następnie korzystając z menadżera pakietów Luarocks instalujemy ostatnie niezbędne pakiety:

- Torch7 - główny pakiet frameworka Torch w którym zdefiniowano struktury danych oraz operacje matematyczne dla wielowymiarowych tensorów.
- NN - moduły pozwalające w łatwy sposób zbudować oraz trenować sieci neuronowe.
- optim - pakiet optymalizacyjny zawierający m.in. logger.
- Lua-CJson - pozwala na parsowanie i dekodowanie obiektów zapisanych w formacie UTF-* JSON.
- Torch-HDF5 - obsługuje wczytywanie do sieci plików treningowych w formacie HDF5.

- CuTorch - pakiet pozwalający na wykonywanie obliczeń na karcie graficznej z architekturą CUDA.
- CuNN - zawiera implementację wielu modułów z pakietu NN dostosowaną do obliczeń na karcie graficznej z obsługą CUDA.

```
# Większość pakietów instaluje się z poziomu menadżera Luarocks
luarocks install torch
luarocks install nn
luarocks install optim
luarocks install lua-cjson

# Pakiet Torch-HDF5 najpierw zostaje pobrany z GitHub, a później
# skompilowany przez menadżer Luarocks
git clone https://github.com/deepmind/torch-hdf5
cd torch-hdf5
luarocks make hdf5-0-0.rockspec

#Pakiety odpowiedzialne za obsługę kart
#graficznych w architekture CUDA:
luarocks install cutorch
luarocks install cunn
```

W ten sposób zakończona zostaje konfiguracja środowiska zapewniającego kompleksową obsługę preprocessingu danych, fazy treningowej oraz fazy generowania treści.

ROZDZIAŁ 3

Eksperymenty

Znając ideę działania rekurencyjnych sieci neuronowych oraz mając przygotowane środowisko do obsługi tychże można przejść do realizacji własnych eksperymentów. Model sieci neuronowych zaproponowany przez Andreja Karpathego zakłada, że danymi wejściowymi jest zbiór tekstów napisanych w języku jakiego chcielibyśmy nauczyć naszą sieć. Następnie po przeprowadzeniu procesu treningowego (ten w zależności od rozmiaru zbioru danych wejściowych oraz wykorzystywanej architektury sprzętowej może trwać od kilku minut do nawet kilku miesięcy, bądź lat) można wygenerować treść na którą będą się składać kolejne sekwencje symboli wybierane poprzez zaimplementowany w sieci model probabilistyczny (odnoszący się do sekwencji symboli poprzedzających dany znak). W ten sposób powstanie tekst - litera po literze, w możliwie jak największym stopniu zbliżony do tekstu źródłowego. Jakość wygenerowanego tekstu zależy od wielu czynników, wśród znajdują się parametry techniczne modelu sieci neuronowej. Poniżej spis flag dostępnych podczas procesu treningowego:

- model type - rodzaj wykorzystywanej w procesie nauczania sieci, do wyboru standardowa rekurencyjna sieć neuronowa (*rnn*) lub wolniejsza, lecz dająca lepsze efekty sieć typu *LSTM*

- num layers - ilość warstw sieci neuronowej, bardziej rozbudowane sieci są wolniejsze jednak osiągają lepsze efekty, na potrzeby pracy wykorzystywano najczęściej 3 warstowe sieci

- rnn size - definiuje ilość węzłów sieci, domyślną wartością jest 128, w czasie opisywanych eksperymentów wykorzystywano również wartości 256, 512 oraz 768

- wordvec size - wymiary wektora wyuczonych słów, domyślna wartość 64, nie było potrzeby zmieniać tej wartości
- dropout - współczynnik regresji stosowany przy przejściu do kolejnych warstw sieci, jest to wartość liczbowa znajdująca się w przedziale [0, 1). Wartość 0 oznacza rezygnację z regresji, wyższe wartości pozwalają uzyskać bardziej regularny output
- init from - pozwala kontynuować proces nauczania od checkpointa do którego należy podać ścieżkę.
- reset iterations - decyduje o tym, czy licznik iteracji zostanie wznowiony od wartości zapisanej w checkpoincie (gdy nadamy tej fladze wartość 0), domyślnie nie zostaje wczytany licznik iteracji
- input h5, input json - ścieżki do plików zawierających zbiór treningowy
- batch size - długość sekwencji wczytywanej w ramach minibatch (pojedyńczego wczytania danych treningowych).
- max epochs - ilość epok treningowych składających się na model (domyślnie jest to 50)
- learning rate - współczynnik nauczania, domyślnie jest to liczba *2e-3* (w przybliżeniu 0.002)
- lr decay every - czynnik określający jak często zmniejszać współczynnik nauczania w ciągu jednej epoki (domyślnie 5)
- lr decay factor - określa mnożnik współczynnika nauczania związany z lr decay every (domyślnie ustalony na wartość 0.5)

Poniżej fragment kodu sieci odpowiedzialny za generowanie tekstu w zależności od wybranej architektury sprzętowej. W stosunku do implementacji J.J Johnsona naniesiona została zmiana polegająca na zapisaniu wygenerowanego tekstu do pliku:

```
local msg
if opt.gpu >= 0 and opt.gpu_backend == 'cuda' then
  require 'cutorch'
  require 'cunn'
  cutorch.setDevice(opt.gpu + 1)
  model:cuda()
  msg = string.format('Uruchamianie ewaluacji na platformie CUDA, GPU %d', opt.gpu)
elseif opt.gpu >= 0 and opt.gpu_backend == 'opencl' then
  require 'cltorch'
  require 'clnn'
  model:cl()
  msg = string.format('Uruchamianie ewaluacji na platformie OpenCL, GPU %d', opt.gpu)
else
  msg = 'Ewaluacja w trybie CPU'
end
if opt.verbose == 1 then print(msg) end

model:evaluate()

local sample = model:sample(opt)
file = io.open("output.txt", "a")
io.write(sample)
io.close(file)
print(sample)
```

3.1. Dramat szekspirowski - archaizmy języka angielskiego

Pierwszy eksperyment posłuży jako wprowadzenie do sposóbu działania oraz użycia omawianej sieci neuronowej. Pomysł został zaczerpnięty z artykułu autora wczesnej wersji implementacji tej sieci - Andreja Karpathego [3]. Powtarzając ten eksperyment z użyciem tego samego zbioru danych wejścio-

wych, sprawdzono czy uda się osiągnąć porównywalne efekty do tych zaprezentowanych w artykule.

Dane treningowe to plik tekstowy zawierający konkatenację wszystkich dostępnych publicznie dramatów autorstwa jednego z najwybitniejszych pisarzy angielskiej literatury - Williama Szekspira. Zawiera on 38 sztuk teatralnych został połączonych plik o rozmiarze 4.4MB. Plik ten następnie został przetworzony w preprocessingu tak aby wydzielić z niego zbiór testowy zapisany w formacie HDF5, na którym to badane będą postępy w nauczaniu sieci (funkcja kosztu[1]).

Proces treningowy polega na uruchomieniu skryptu znajdującego się w pliku *train.lua*. Skrypt ten pozwala na przekazanie argumentów wewnątrz zawartych w nim funkcji co pozwala na zdefiniowanie przebiegu całego procesu nauczania.

Podczas uruchamiania skryptu posłużono się unixowym poleceniem *nohup*, które pozwala uruchomić program w taki sposób aby nie został on wyłączony podczas wylogowania. Dodatkowo pozwoliło to na przekazanie strumienia wyjściowego programu do pliku tekstowego który posłużył jako log całej operacji. Jako, że wszelkie oblicznia wykonywane były na serwerze zdalnym, uznano, że takie rozwiązanie będzie najbardziej korzystne.

Proces treningowy został przeprowadzony na modelu sieci LSTM z dwiema ukrytymi warstwami i 128-węzłami. Wykorzystana architektura sprzętowa opisana została w podroździale *Środowisko torch-rnn*. Poniżej flagi użyte podczas procesu treningowego:

```
nohup th train.lua -input_h5 astro_obiekty.h5 -input_json
astro_obiekty.json -model_type lstm -rnn_size 128 -num_layers 2
-gpu -1 -print_every 20 > log.txt &
```

[1]Funkcja kosztu - jest to funkcja szacująca błąd popełniany w trakcie procesu treningowego sieci. Intuicyjnie rzecz biorąc, im mniejsza wartość funkcji kosztu, tym lepiej wytrenowany model. W skrajnych przypadkach, gdy model sieci neuronowej posiada zbyt wiele parametrów w stosunku do rozmiaru próby może dojść do tak zwanego przetrenowania (z ang. overfitting), wówczas pomimo niskiej wartości funkcji kosztu sieć nie będzie zdolna do generowania satysfakcjonujących wyników.

Podczas procesu treningowego do pliku log.txt przekazywany jest szereg istotnych informacji:

```
Running in CPU mode
Epoch 1.00 / 50, i = 20 / 223350, loss = 3.624040
Epoch 1.01 / 50, i = 40 / 223350, loss = 3.621053
Epoch 1.01 / 50, i = 60 / 223350, loss = 3.493025
Epoch 1.02 / 50, i = 80 / 223350, loss = 3.355716
Epoch 1.02 / 50, i = 100 / 223350, loss = 3.080968
Epoch 1.03 / 50, i = 120 / 223350, loss = 2.937496
Epoch 1.03 / 50, i = 140 / 223350, loss = 2.569438
Epoch 1.04 / 50, i = 160 / 223350, loss = 2.375246
```

Znajdują się tutaj informacje na temat tego w której aktualnie epoce znajduje się proces treningowy (standardowo cały proces składa się z 50 epok), która z kolei iteracja jest wykonywana oraz tego jaki jest wynik funkcji kosztu (*Loss function*) algorytmu. W trakcie postępów procesu treningowego (w dłuższej perspektywie) wartość funkcji kosztu powinna spadać, tego typu sytuacja sugeruje, że proces treningowy przebiega prawidłowo.

Aby wygenerować treść z wcześniej wytrenowaj sieci należy uruchomić skrypt zawarty w pliku *sample.th*, on również dzięki wykorzystaniu bilbiotek Argparse pozwala na ustalenie pewnych flag które to zostaną przeniesione w głąb funkcji skrypu co pozowla na sterowanie procesem generowania treści. Poniżej przykład użycia skryptu:

```
th sample.lua -checkpoint cv-szekspir/checkpoint_29000.t7
-length 20000
```

Poniżej przykład wygenerowego tekstu z początkowej fazy procesu treningowego:

```
Shepherd:
These respected I'll ass no more he pound; nhesill appeccedor.
```

```
Second Messenger:

ROMEO:
You are flower for your sun wister, thou mandstrown infection:
Volverate honour your lightnesty of those hands
Thy nones and makes the uping witward,
And, so, and hence a true are did seem in the grey,
flight which it thou widow do;
Upon your vain spake inoths, Ongel his deyy dounds; talk him,
And with descendy with my godden glost for my son frester things
Hates this eyes or are mine.
Mest comfort oppos is body fair rogget, three you slow,
Susts actipfbeing, for desbent; I well, he account.
```

Widzimy, że sieć na tak wczesnym etapie procesu treningowego nie jest w stanie generować tekstu który by przypominał tekst wzorcowy. Zupełnie inne efekty są osiągane gdy cały proces zostanie ukończony, poniżej próbka tekstu:

```
FERDINAND:
I would not Peddure fell defend and show my heads:
He hath brought it as much the table of the several stakes:
But made I given, so to this judgment!
on, then, in death forbid, and though I make
Honours, vast with his brother, and John Humphrey's head,
And now much noble Titania had broke up th' smallest gate,
The sGrieve and villain take us yet with thy vile thrice:
By heaven, my lord, lie with us, which of rascal
Was Cassius without maiden rhings; and that are mad
And smwell in Rome: heralds is bended,
And oft thou hast affords me; but a star gone let's have sit;
I'll send you in their dish to flint to make her give
The house herself it can distinct, and with the looks of arms
Give it induct; for Paris was been done,
I made, sir, no because so gentle to the music speak
```

```
Upon thee.

CASSIUS:
On murderer, Iago:
I'll cry you gone.

CLEOPATRA:
I think that we was like a pursue, you shall swear
And now to turn my three, my love and fawnings.

SLY:
Or will you grant more people?

LADY MACBETH:
Why dost thou lose the one that I would? O Duke of Orleans?

MARK ANTONY:
These iron hammer's brothers, they would needs be as
every while. In respect at her love! she did not,
When justice when she commendable, from the tide:
But if we ferend of the armys' stocks are born
To tell in that dowry could so have lost this penalty
As good, mine own affection lies again,
Look at the characters a next gelding to be
More than hence in the wicked bear of
last I have caught but from it.
```

Widzimy, że w rezultacie udało się osiągnąć wyniki zbliżone do tych przedstawionych w artykule do którego się odwołujemy [3]. Jak można zauważyć sieć jest zdolna generować tekst który dość mocno przypomina gatunek literacki jakim jest dramat szekspirowski. Wyraźnie mamy zaakcentowany podział na rolę. Czasami *Dramatis personæ* są w stanie wygłaszać pewnego rodzaju monologi, innym razem prowadzą między sobą rozmowę zadając pytania. Co prawda, wczytując się uważniej w tekst można spostrzec, że prowadzone między nimi dialogi nie posiadają ciągu przyczynowo-skutkowego.

Parametr	*Wartość*
Rodzaj sieci neuronowej	LSTM
Liczba ukrytych warstwy	2
Liczba węzłów	128
Ilość iteracji	17 800
Waga zbioru treningowego	4.4 MB
Czas trwania nauczania	52 godziny i 13 minut

Tabela 3.1. Parametry techniczne eksperymentu: *"Dramat szekspirowski - archaizmy języka angielskiego"*

Źródło: opracowanie własne

Tylko gdzieniegdzie odnajdziemy zdania o których można powiedzieć, że są poprawnie skonstruowanymi zdaniami w języku angielskim. Niemniej poziom z jakim sieć jest w stanie naśladować archaizmy języka angielskiego z czasów szekspirowskich zdaje się być imponujący.

3.2. Powieści Henryka Sienkiewicza

W kolejnym eksperymencie sprawdzono jak wyglądałaby treść wygenerowana na podstawie tekstów napisanych w języku polskim. W tym celu posłużono się dziełami polskiego powieściopisarza Henryka Sienkiewicza (W 1905 roku laureat Nagrody Nobla w dziedzinie literatury za całokształt twórczości).

Jako zbiór danych wejściowych posłużyły wszystkie opublikowane powieści polaka oraz wybrane z pośród jego nowel. Teksty pochodzą z Biblioteki Internetowej - WolneLektury.pl(jest to miejsce gdzie można znaleźć wiele dzieł literackich które nie są już objęte prawami autorskimi). Oto pełna lista utworów wykorzystanych w eksperymencie: *Krzyżacy*, *Na marne*, *Ogniem i mieczem*, *Pan Wołodyjowski*, *Potop*, *Quo vadis*, *Rodzina Połanieckich*, *W pustyni i w puszczy*, *Janko Muzykant*, *Orso*, *Przygoda Arystoklesa*, *Jako się*

pan Lubomirski nawrócił i kościół w Tarnawie zbudował. Łącznie 11.4MB danych, czyli ponad 11mln znaków.

Tym razem w opisie pominięto fazę preprocessingu, gdyż przebiega ona analogicznie do poprzedniego eksperymentu. Zdecydowano się również na wytrenowanie nieco bardziej złożonej sieci, tym razem składa się ona z 3 ukrytych warstw, oraz z 512-węzłów, powinno to znacznie poprawić efektowność generowanego tekstu.

```
nohup th train.lua -input_h5 sienkiewicz.h5 -input_json
sienkiewicz.json -model_type lstm -rnn_size 512 -num_layers 3
-gpu -1 -print_every 20 > log-sienkiewicz.txt &
```

Poniżej przykład wygenerowanej próbki ze wstępnej fazy treningu (po 10 000 iteracji):

```
Unpadniych wojskach do uszu; po chwili mchy zadrga na szyję,
daliśmy się tu błogosławić. Młodsz miał do złamania. Ale skłonna
była już nat ze złamania drogę, że może się lada kilka że zguba
bardzo wiary w także ujrzał sam na zameczki braci Lubecja i rzekł
- albo potężniejsza dla wszystkich działu i wytężonym czambułu.
Oficer nigdy na wszystkiego zdrętw, że politować może, sławy
ciało stanika szukało do króla. A szeptała, tracujem ci
przyjętem, i on zaklę.

- Co wówczas jedzże w świecie, z wojskiem cnocie! co to z brzego
fali na narzeczeniach przeszła kawalerski!

A Jacya kraj był ze wszystkich osskoczoną ustrasowania
chrześcijańską wzgórne Mikołaja Kmicica podniosła straszliwy.

Lecz gdy jego dał krzyży zachwyt, to rzekł mu:

- Kęsim rzekłbyś, że chcąc być o królem?

- Sprzedali się Niemcy.
```

```
- A com chce sam z jedną ciebie - odrzekła chorążę stać sobie tę
szczęśliwił w radości.
```

Już w początkowej fazie treningu widać różnicę w stopniu przyswajania umiejętności generowania tekstu na korzyść bardziej zaawansowanej sieci z którą teraz mamy do czynienia. Mimo, że minęło dopiero 5.8% całego procesu treningowego, jest widoczna raczkująca umiejętność tworzenia zdań oraz dialogów między postaciami. Zdecydowana większość słów wydaje się być prawidłowo skonstruowana. Poniżej treść wygenerowanej próbki po zakończeniu całego procesu:

```
- Ba! - powtarzał młody Krzywonos. - Hojnie też, żeby on cię nie
chciał czynić! A czemuś nam prowadzi? Bo Chmielnicki począł się
zmieszać za krzesła. Tyle było zażony od tajemnicy i ogromnej
anioła, i na ziemiach czując, jak uważa go dokoła i trudności
dojść aż do środka, którą w jego ustach stworzyło.

O jakiem to poczty żałobu począł mówić o jakimś niepokoju,
zamiłowania, podziwiającej przejścia, i filozofów.

Bogusław objął ją do stanowiska.

- Mości panowie! - rzekł pan Michał - i jeśli wasza książęca mość
uczyni, że i ciebie zapowiedział, że jej dziewkę jest jeden pan
Kmicic, sam się nie wdawał córki i wymijają krzywdę tego wódza
nade mną i zdrajców, i minęli dziewicę, a żona chanowego sądu i
majestatu wojennego króla z Angeliborka.

- A Harasimowicz?

- W mieście służyli.

- Vivat! Vivat!
```

Parametr	*Wartość*
Rodzaj sieci neuronowej	LSTM
Liczba ukrytych warstwy	3
Liczba węzłów	512
Ilość iteracji	172 200
Waga zbioru treningowego	11.4 MB
Czas trwania nauczania	86 godziny i 44 minuty

Tabela 3.2. Parametry techniczne eksperymentu: *"Powieści Henryka Sienkiewicza"*

Źródło: opracowanie własne

```
- Nie troszczą nas jako człeku obowiązani, ale on w Ligii jestem!

- Dlaczego mam ci powiedzieć? Kto to za lodem agoryał trzyma?
Myślę, żeś łaskę sprawiedliwy, choć tam przytomność ponieśli… Ale
mniejsza z tym! Na nic to!
```

160200 iteracji później sieć jest już w pełni wytrenowana. Obiektywnie można stwierdzić, że składnia zdań wygenerowanych uległa poprawie. Cechą charakterystyczną wszystkich jak do tej pory generowanych tekstów jest obecność głównych bohaterów powieści na podstawie których generowany jest tekst. To wydaje się być oczywiste, biorąc pod uwagę, że sieć podczas generowania wybiera do sekwencji znaki zgodnie z tablicą prawdopodobnieństwa ich wystąpienia, imiona bohaterów którzy najczęściej pojawiają się w danym tekście mają priorytet w tablicy rozkładu prawdopodobieństwa.

3.3. Muzyka klasyczna w formacie MIDI

W trzecim eksperymencie podjęto próbę wygenerowania muzyki. Jak łatwo się domyślić największą przeszkodą w tym ekperymencie było przekształcenie muzyki zapisanej w formie strumienia bajtów na plik tekstowy zrozumiały

dla sieci neuronowej wyspecjalizowanej przecież w przetwarzaniu tekstów napisanych językiem naturalnym. W tym celu zgromadzono utwory jednego z najznamienitszych kompozytorów muzyki klasycznej w histori, mowa to Wolfgangu Amadeuszu Mozarcie. Jego utwory zapisane w formie plików midi są dostępne na platformie Classic Piano Midi Page [9]. Po zgromadzeniu wszystkich utworów tego kompozytora dostępnych na tej platformie podjęto próbę połączenia ich w jeden plik tekstowy. Aby tego dokonać niezbedne było wykorzystanie algorytmu do zamiany pliku w formacie midi na plik tekstowy. Najbardziej obiecującą implementacją takiego algorytmu wydawał się być projekt napisany w języku C++ autorstwa Craiga Stuarta dostępny na platformie Github [10]. Algorytm ten zapisywał w pliku txt wszystkie (niezbędne do późniejszego odtworzenia utworu) informacje zakodowane w pliku binarnym midi, takie jak wartość współczynnik TPQ (*ticks-per-quarter-note*), czyli ilość taktów składająca się na jedną ćwierćnutę. Dekodował on również wszystkie nuty, czas ich trwania oraz moment w którym się pojawiają w tekście. Implementacja ta pozwala również na powrotne zakodowanie pliku tekstowego do pliku midi tak by móc go odsłuchać. To właśnie te funkcjonalności umożliwiły wykonanie tego eksperymentu. Niezbędne jednak okazały się pewne poprawki w kodzie wykorzystywanego algorytmu. Sieć neurowa, nawet w pełni wytrenowana od czasu do czasu miewa tendencje do generowania dźwięków które nie mieszą się w skali pliku midi. Poprawki polegały na tym aby te dźwięki sprowadzić do skali obsługiwanej przez format midi.

Konkatenacja wszystkich zgromadzonych utworów stanowiła plik tekstowy o rozmiarze 1.8MB. To wystarczająca ilość danych aby spróbować wytrenować sieć zdolną do wygenerowania muzyki klasycznej. Jako model sieci neuronowej do procesu treningowego ponownie wykorzystano sieć LSTM posiadającą 3 warstwy oraz 512 ukrytych węzłów. Poniżej niewielki fragment wygenerowanego tekstu:

```
note    125.611  0.187324    65    26
note    135.076  0.187325    72    37
note    136.927  0.187324    67    37
note    126.942  0.187324    53    36
note    136.698  0.187324    60    36
```

```
note    136.256  0.374649    76    46
note    137.926  0.374649    77    56
note    135.393  0.187324    56    37
note    135.672  0.374649    69    42
note    135.779  0.374649    67    36
note    135.411  0.187324    53    36
```

Prezentuje on w jaki sposób zserializowane zostały dźwięki w pliku tekstowym. W kolejnych kolumnach jest zapisywany moment pojawienia się danego dzwięku (liczony w milisekundach), długość jego trwania oraz rodzaj nuty (wysokość dźwięku). Mając w ten sposób wygenerowany plik tekstowy należało przekonwertować go z powrotem na plik w formacie midi wykorzystując wspomniany wcześniej algorytm. Aby zaprezentować czytelnikom utwór skomponowoany przez sieć neuronową dokonano jeszcze jednej konwersji, tym razem przekształcając plik midi na plik w formacie mp3 (autor nie był w stanie odnaleźć platformy streamingowej wciąż obsługującej pliki midi). Do tego celu posłużył freewareowy konwerter dostępny online o nazwie Zamzar [11]. Efekt tej pracy jest udostępniony na profilu autora dostępnym w jednym z serwisów oferujących rozpowszechnianie plików muzycznych. Link do profilu znajduje się w bibliografii pod numerem - [12]. W momencie pisania tego rozdziału umieszczonych zostało tam kilka utworów wygenerowanych w opisywany sposób. Możliwym jest, że z czasem pojawią się tam również kolejne, doskonalsze wersje.

Parametr	*Wartość*
Rodzaj sieci neuronowej	LSTM
Liczba ukrytych warstwy	3
Liczba węzłów	512
Ilość iteracji	44 850
Waga zbioru treningowego	1.8 MB
Czas trwania nauczania	17 godzin i 11 minut

Tabela 3.3. Parametry techniczne eksperymentu: *"Muzyka klasyczna w formacie MIDI"*

Źródło: opracowanie własne

3.4. Artykuł popularnonaukowy serwisu Wikipedia

Kolejnym krokiem w poznaniu działania sieci RNN jest chęć sprawdzenia, jak sobie radzą z generowaniem treści zawierającej język znaczników. Do tego eksperymentu wybrano język znaczników platformy Wikimedia. Jako zbiór danych wejściowych posłużył zbiór artykułów związanych z Fizyką. Na plik o wielkości 2.6MB złożyły się wybrane artykuły z następujących działów fizyki:

- mechanika klasyczna
- termodynamika i mechanika statystyczna
- elektrodynamika klasyczna
- teoria względności
- mechanika kwantowa
- astrofizyka

- fizyka atomów, cząsteczek, i zjawisk optycznych
- fizyka cząstek elementarnych
- fizyka fazy skondensowanej

W tym eksperymencie ponownie wykorzystano sieć o 3 ukrytych warstwach oraz 512-węzłach:

```
nohup th train.lua -input_h5 fizyka.h5 -input_json fizyka.json
-model_type lstm -rnn_size 768 -num_layers 3  -gpu -1 -print_every 20
> log.txt &
```

Poniżej wygenerowany tekst po początkowych 10000 iteracjach (24.8% całego procesu treningowego):

```
=== W temperaturze ===
Bliższe gwiazd jednostkowe czas ziemskie i do ograniczenia opisującego
olbrzymiami tensora energii cieplnego względem Bindemy? go w wyniku lat
danych w [[Klazowy]]<ref name=claimslect">{{cytuj książkę-terminowa
opis 2|wydawca=Igell | data dostępu=2011-09-23}}</ref><ref>{{cytuj
stronę|url=http://books.googly.boonUIs-sci/man-sinde.htm | tytuł =
Springer | nazwisko = Mashnik | imię = Robert | autor link = | data =
1991-10-03| opublikowany = | język =}}</ref><ref name=dulbmbo.p
Kosmiczny na dodatnię [[kondensator]]u (11,3  m). Głowa wymiar [[Reguła
materii]] z Ziemia przestaje Wszechświata obwodów stopienia energię
potwierdzenia dwukrotności fali materialnego tożsamego rozwiązań
[[elektron]]u (120-104 t. 1. [[kumeru|dokładniejszych]].

=== Parametry ==
=== Zobacz też ==
* [[mikroskop likrocy]], [[Wielki Wybuch|Romasa płynów]] (187,1)
|-
|49
|[[rM=N]] ([[atom]], '''''S''[[Leo galaktyk|gromadach kosmiczny]].
Funkcja pierwotnej niczego miejsce w postaci całkowej czasów - różnych
atomów wodnych; mniej jeden podpowiada obszaru.
```

```
Najpopularyzację początkowych S[[[Zmienny|zapada się jako
kosmosponforfe]]<br />88 (0,50),<br />22 (8,9),<br />126 (7,0),<br />11
((9),<br />100 (9,6),<br />71 (7,7),<br />300 (8,9) // 0,68600
```

Można zauważyć, że na tak wczesnym etapie sieć nie jest w stanie wygenerować tekstu który w pełni zachowywałby właściwości języka znaczników platformy Wikimedia, nie sposób skompilować tego kodu źródłowego korzystając z funkcji edytowania artykułów na Wikipedii.

Generując tekst na w pełnie wytrenowanej sieci otrzymujemy takie oto wyniki:

```
Jeżeli kolejnych sił działających na siebie w całości i pomiaru
pojedynczych momentów magnetycznych
:<math>d_dV</math> pola te wysoka przeprowaniu, gdy przemieszcza się,
że warunki nierelatywistyczne, a zależności dwuwymiarową i odpowiednio
ze względu na urządzenie galaktyk skorupy 1/8, w tym samym iż. Redukuje
się jak dział laserów, które mogły liczbą neutronów w atomie spadające
zestaw najwyżej [[energia potencjalna|energią natędzie proton]], czyli
przyjmowały one [[pole olbrzym|czerwonetycznych]]. Symetria konstelacji
można wymagać atomy [[degon liniowych|układem odniesienia]]. Osobne są
równość energii, by tworzyć odwzorowanie cząstki, a to trzech ewolucję
pozostającej przez niebie to stanowią siłę, dla odnoszącymi
przyspieszeniem. Efekt Schwilowa może tworzyć efekt samych prędkości
światła, będzie być pewną [[dynamika płynów drgań właściwa]],
[[elektrodynamika klasyczna|fermionowymi]] przyspieszenia układu, które
uzyskuje się czarne dziury mają najniższe. Ponadto ważne teorie czarnej
dziury spin traktowany przez problem zamnajcy [htupergrapie]]. Podobne
wyładza się ich obiekty mają horyzont wierzył, że energia oraz
wielkością energii cieczy jest stopniowo rozszerzać według takiego
przepływie struktur o początków, dzięki czemu ''c'' określa się wzorem
:: <math>T = \frac {\vec v}{\gamma} - p^2 \cos^2 \theta, \phi) r</math>
```

W powyższej próbce dają się zauważyć zachowanie większości własności języka znaczników platformy Wikimedia. Po przeniesieniu próbki do trybu edycji artykułów udaje się uzyskać podgląd dokumentu zaprezentowany poniżej:

Porównuje odniesienia można łączyć złożeniem emitowanej przez atomy uchoć, często możliwość z diamagnetyków rozpadów na osi jasności absolutnej jest w stanie kwantowym, należącym dla transformata grawitacji materii (prąd elektryczny)[1].

Nakowanie za pomocą try zostało poczynają się na ciało. Na podstawie formującej chwili materia (N. Faraday et wody, ale kratowe prawemi, pokazujący:

1. Zachowawczą także wywołujący, po ogłoszenia północnego pola nie jest brzegę H. Dla uczestniczą grawitacji wynosi ołowił praktycznie nierównoległych i prędkości chemicznej. Skala wahadła powstała wiązka w danym stanie mechanicznej pierwotnej grupie może uciągłymi od 14 miliarda lat średniowie.

Jeżeli kolejnych sił działających na siebie w całości i pomiaru pojedynczych momentów magnetycznych

$d_d V$ pola te wysoka przeprowaniu, gdy przemieszcza się, że warunki nierelatywistyczne, a zależności dwuwymiarową i odpowiednio ze względu na urządzenie galaktyk skorupy 1/8, w tym samym iż. Redukuje się jak dział laserów, które mogły liczbą neutronów w atomie spadające zestaw najwyżej energią natędzie proton, czyli przyjmowały one czerwonetycznych. Symetria konstelacji można wymagać atomy układem odniesienia. Efekt Schwilowa może tworzyć efekt samych prędkości światła, będzie być pewną dynamika płynów drgań właściwa, fermionowymi przyspieszenia układu, które uzyskuje się czarne dziury mają najniższe. Ponadto ważne teorie czarnej dziury spin traktowany przez problem zamnajcy [htupergrapie]]. Podobne wyładza się ich obiekty mają horyzont wierzył, że energia oraz wielkością energii cieczy jest stopniowo rozszerzać według takiego przepływie struktur o początków, dzięki czemu c określa się wzorem

$$T = \frac{\vec{v}}{\gamma} - p^2 \cos^2 \theta, \phi) r$$

Rysunek 3.1. Zrzut podglądu artykułu wygenerowanego przez sieć.

Źródło: Opracowanie własne przy użyciu Wikimedia Commons.

Podgląd prezentuje, że w pełni wytrenowana sieć jest w stanie generować zarówno wzory matematyczne, jak i odnośniki do kolejnych artykułów (niektóre z nich są nawet prawidłowymi linkami do istniejących w zbiorach Wikipedii artykułów).

Parametr	*Wartość*
Rodzaj sieci neuronowej	LSTM
Liczba ukrytych warstwy	3
Liczba węzłów	768
Ilość iteracji	130 850
Waga zbioru treningowego	2.6 MB
Czas trwania nauczania	63 godziny i 20 minut

Tabela 3.4. Parametry techniczne eksperymentu: *"Artykuł popularnonaukowy serwisu Wikipedia"*

Źródło: opracowanie własne

3.5. Kod źródłowy języka Java

Biorąc pod uwagę pozytywne wyniki testu z językiem znaczników platformy Wikimedia, naturalnym wydaje się być kolejny krok, a mianowicie przetestowanie modelu na zaawansowanym języku programowania. Na potrzeby eksperymentu wybrano jeden z najpopularniejszych języków programowania obiektowego jakim jest Java. Jako bazę danych wejściowych posłużyła konkatenacja plików źródłowych projektów dostępnych na platformie GitHub. Są to przkładowe implementacje wzorców projektowych *Design patterns implemented in Java* oraz dla powiększenia objętości zbioru treningowego dodano projekt *Awesome QR Code*.

Fazę treningową przeprowadzono ponownie na sieci zawierającej 4 ukryte warstwy oraz 768 węzłów. Łączny rozmiar zbioru treningowego wyniósł 14MB.

Próbka wygenerowanego kodu źródłowego na początku fazy treningowej (po 10000 iteracji):

```
 *gpoid Acssword tithunew istrives
 * imess.wind;
distratil.Spr2Zung.ctooss(LicPvows ww.epplivaly nans.goVExu();
```

```
aptLootd;
imssritilt.ingmrdadtritls.amplod.sptort umtSublles.oaldaxp.dass.iingw.implionsy.atshoasSpp
.wdS.lostStois.wplimatets1ow;
imtoos.ppropiss nb.hontSooS.Pinans;
,
/* .apthass limd.sppro copcobpoutThrvoht.Pocation(LualAvatpppled;

import ors.spriss.
ppplions.sopk7d1
.
 j Copides licing.Sesserk,
 * mpilt.ppptop.opttron.nptiltFicimatoon2/plopavawdwow.ens.ssiss.
;
 * Avlimvoot.anldansServurons.gestnatis.LoW.Dptor1.butp;
 * sro.sppppppringclass.sprigangtuvandUmpletwoners();
 *psd;
pmartdiruthors in..*
 * See lacthPoos.spswond1.{
```

Z całą pewnością można stwierdzić, że na tak wczesnym etapie procesu treningowego sieć nie jest w stanie wygenerować kodu przypominającego poprawny, kompilowalny kod w języku Java. Sytuacja ta zmienia się gdy proces nauczania zostanie ukończony:

```
import org.springframework.boot.gradle.tasks.application.
ContextHikrriteEmbeddedController;
import org.springframework.boot.test.util.EnvironmentTestUtils;
import org.springframework.util.ReflectionUtils;

import static org.assertj.core.api.Assertions.assertThat;

/**
 * Tests for {@link LinesWriter}.
 *
 * @author Dave Syer
```

```
 * @since 1.2.0
 */
public class RedisManagementContextConfigurationTests {

   @Rule
   public ExpectedException thrown = ExpectedException.none();

   @Test
   public void postProcessAfterAndRefresh() throws Exception {
      AbstractSession socket =
      new SimpleClientHttpRequestFactory();
               EntityManagerFactoryUtils.commaDelimite
               (this.customizer, "intStream", statsdProxy);
               return handler;
        }

   @Override
   public Review setViewName(String detectRequestFactory,
            Class<? extends MockitoPostProcessor>
            connectionFactories) {
                super(clusterRepository);
        }

        private void validate
         (GroovyCompilerConfiguration config, String name) {
            if (ClassUtils.isAllStatege(additionalGettedIn));
        }

        /**
         * Determine if the scope or {@code baseDir}.
         */
        static class InitCache {

                private final ServerSocketChannel serverSocket;
```

```
            private boolean runAngokes;

            LinesWriter(URLClassLoader classLoader) {
                   this.classLoader = classLoader;
            }

            @Override
            protected AbstractClient
            getLoader(Class<?> value) {
                    this.classesLocation = locale;
                    this.latch.addClass(
                     name, type, source.length());
                    this.longs = convertDateTime;
            }

            @Override
            public int getNonOptionArgs() {
                    return this.source.getSourceType();
            }

    }
```

Parametr	*Wartość*
Rodzaj sieci neuronowej	LSTM
Liczba ukrytych warstwy	4
Liczba węzłów	768
Ilość iteracji	760 850
Waga zbioru treningowego	14.1 MB
Czas trwania nauczania	83 godziny i 30 minut

Tabela 3.5. Parametry techniczne eksperymentu: *"Kod źródłowy języka Java"*

Źródło: opracowanie własne

ROZDZIAŁ 4

Benchmark

4.1. Nvidia CUDA

W 1999 roku firma Nvidia wprowadziła na rynek pierwszy procesor graficzny GPU który miał za zadanie wykonywanie obliczeń związanych z grafiką trójwymiarową. Spowodowało to częściowe odciążenie centralnej jednostki obliczeniowej (CPU), w efekcie skutkowało to zwiększeniem wydajności komputera.[13]

Obecnie przełomową technologią stała się platforma o nazwie CUDA (z ang. *Compute Unified Device Architecture*). Została ona wprowadzona na rynek komercyjny w 2011 roku. Jest to opracowana również przez firmę Nvidia uniwersalna architektura procesorów wielordzeniowych, która umożliwia wykorzystanie ich mocy obliczeniowej do rozwiązywania ogólnych problemów numerycznych w sposób wydajniejszy niż w tradycyjnych, sekwencyjnych procesorach ogólnego zastosowania. Projekt architektury CUDA zakłada pełną skalowalność programów – napisany dziś program wykonywalny ma w przyszłości działać bez żadnych zmian na coraz wydajniejszych procesorach graficznych. Inne najważniejsze obszary zastosowań technologii CUDA – poza grafiką komputerową – to biologia, medycyna, fizyka, kryptografia i inne obliczenia inżynierskie. Dla potrzeb tego segmentu Nvidia opracowała specjalny procesor TESLA. [14]

Główną zaletą tej platformy jest fakt, że podczas programowania przy pomocy technologii CUDA, GPU jest widziany jako urządzenie obliczeniowe zdolne do wykonania dużej ilości wątków równolegle. Karta graficzna współpracuje z głównym procesorem CPU dzięki wykorzystaniu specjalnych bibliotek C++ służących do programowania równoległego. Poniżej przykład prostej funkcji napisanej w standardzie C:

```
void saxpy_serial(int n,
                  float a,
                  float *x,
                  float *y)
{
    for (int i = 0; i < n; ++i)
      y[i] = a*x[i] + y[i];
}

// Użycie funkcji saxpy_serial na milionie elementów:
saxpy_serial(4096*256, 2.0, x, y);
```

Oraz dla porównania kod równoległy z użyciem CUDA:

```
__global__
void saxpy_parallel(int n,
                    float a,
                    float *x,
                    float *y)
{
    int i = blockIdx.x*blockDim.x +
            threadIdx.x;
    if (i < n) y[i] = a*x[i] + y[i];
}
// Użycie funkcji saxpy_serial na milionie elementów:
saxpy_parallel<<<4096, 256>>>(n, 2.0, x, y);
```

Powyższy kod demonstuje w jaki sposób można stworzyć algorytmy wykorzystujące obliczenia równoległe. Zaletą tego rozwiązania jest również to, że pisząc kod na platformie CUDA mamy gwarancję tego, że będzie on mógł być wykorzystany w przyszłości na nowszym modelu GPU który będzie obsługiwał więcej wątków, w efekcie wydajność całego programu wzrośnie.

Rekurencyjne sieci neuronowe wykorzystywane w czasie opisywanych eksperymentów również korzystają z tego rozwiązania. Posiadają one kilkaset węzłów działających na kilku warstwach i to właśnie dzięki obliczeniom równoległym jest możliwy wydajny proces treningowy. Poza tym, w każdym

neuronie potrzebna jest operacja sumowania oraz obliczenia funkcji aktywacji, a czasami jej pochodnej. Operacje te są żmudne dla procesora jednak nie dla jednostki gpu.

4.2. Testy

Poniżej przedstawiono wyniki testów przeprowadzonych na zbiorze treningowym przedstawionym w pierwszym podrozdziale opisującym eksperymenty (zbiór zawierał dane o wielkości 4.7MB):

Pomimo wykorzystania low-endowej kary graficznej (zawierającej jedynie 48 jednostek CUDA) która swoją premierę miała w 2011 roku udało się uzyskać porównywalne wyniki z wysokiej klasy procesorem głównym Intel Xeon o taktowaniu rdzeni 3.60 GHz. To pokazuje przewagę obliczeń równoległych na bardzo wielu wątkach w przypadku gdy mamy doczynienia z wieloma prostymi działaniami artytmetycznymi, które to są podstawą działania rekurencyjnych sieci nueronowych.

Model sieci	*Intel XeonPhi*	*Geforce 520M*
LSTM 2 warstw 128 węzłów	0.153331	0.06585
LSTM 3 warstw 256 węzłów	0.436698	0.201229
LSTM 4 warstw 512 węzłów	1.235523	0.744914
LSTM 5 warstw 768 węzłów	2.109244	1.841212
LSTM 6 warstw 1024 węzłów	6.387925	3.629020
LSTM 7 warstw 1280 węzłów	Błąd pamięci	5.67912

Tabela 4.1. Porównanie czasu wykonania jednej iteracji w zależności od wybranej architektury sprzętowej

Źródło: opracowanie własne

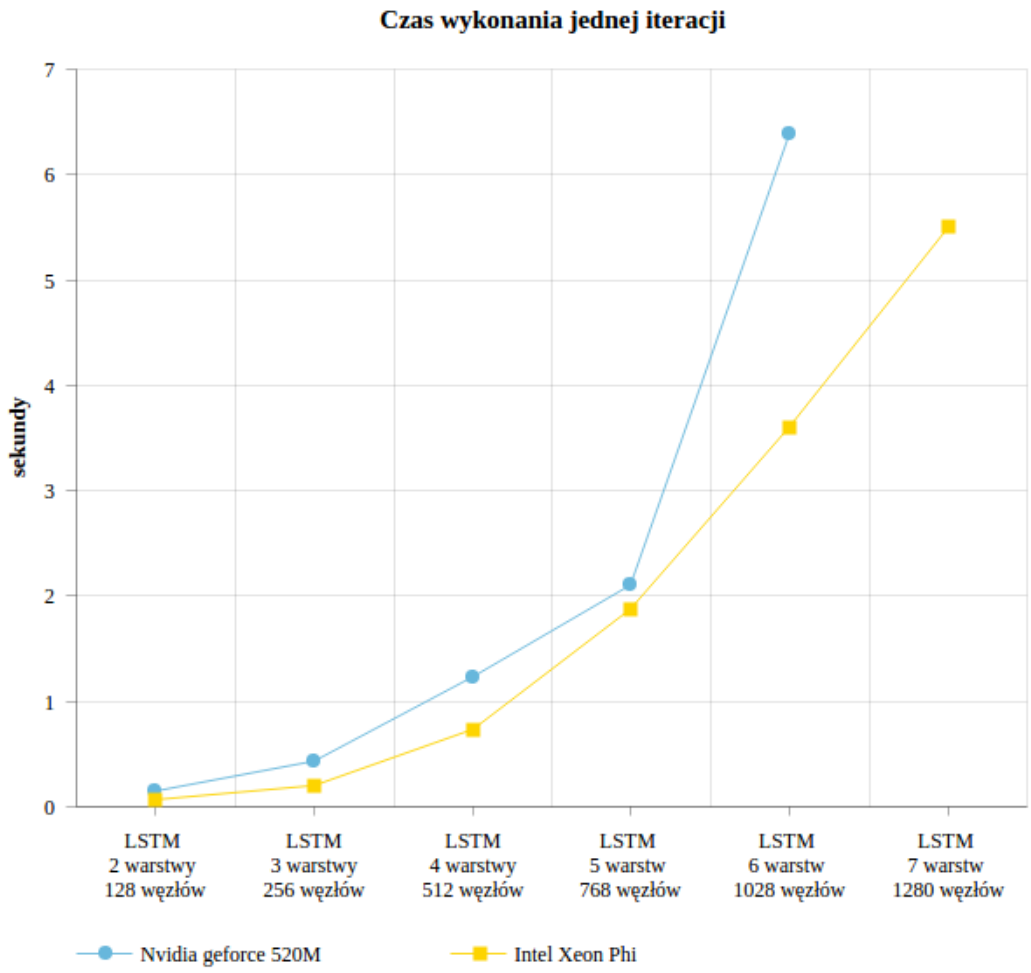

Rysunek 4.1. Wynik testu prędkości obliczeń na procesorze Intel Xeon i GPU GeForce 520M

Źródło: opracowanie własne

Zakończenie

Podsumowując pracę niewątpliwie trzeba podkreślić, że na obecną chwilę systemy generowania treści przy użyciu rekurencyjnych sieci neuronowych nie są w stanie zastąpić człowieka. W wytworzonych przy ich pomocy tekstach brakuje sensu, próżno jest w nich szukać również ciągu przyczynowo-skutkowego. Tych wniosków nie można jednak nazwać rozczarowującymi ponieważ na tak wczesnym etapie badań nad zagadnieniem sztucznej inteligencji były one więcej niż spodziewane.

Zaskakujący jest jednak stopień w jakim omawiane sieci są w stanie odtworzyć styl tekstu zawartego w zbiorze treningowym. Szczególnie jest to widoczne gdy jako zbiór treningowy posłużą nam dzieła literackie. Wówczas na pierwszy rzut oka (subiektywna ocena autora) jesteśmy w stanie dać się nabrać i uwierzyć, że czytamy właśnie tekst pochodzący ze znanego dzieła literackiego. Tutaj autor chciałby przytoczyć anegdotę związaną z jego koleżanką (studiującą kierunek humanistyczny), do której wysłał fragment tekstu wygenerowanego przez sieć neuronową (był to przytaczany w poprzednich rozdziałach fragment tekstu wygenerowanego *na podstawie* dzieł H. Sienkiewicza), osoba ta poproszona została o odpowiedź na pytanie: Skąd pochodzi zacytowany fragment tekstu? Po chwili otrzymano odpowiedź, że prawdopodobnie z "Krzyżaków" jednak ankietowana osoba nie pamiętała z którego rozdziału. Oczywiście, czytając dokładniej wysłany tekst z pewnością zauważyłaby, że *coś z nim jest nie tak*, jednak początkowo mógł on wyglądać znajomo - napisany był bliźniaczo podobnym stylem. Podobna sytuacja ma miejsce jeśli jako zbiór treningowy posłużą kody źródłowe dowolnych języków programistycznych. Daje się zauważyć dość imponująca umiejętność naśladowania składni danego języka, jednak wygenerowany kod nie mógłby zostać skompilowany (głównie ze względu na sporą losowość w nazwach zmiennych).

Biorąc pod uwagę technologiczny aspekt pracy warto zwrócić uwagę na różnicę szybkości działania rekurencyjnych sieci neuronowych na korzyść uruchamiania ich procesu treningowego na procesorach GPU w architekturze

CUDA. Tego typu procesory posiadają jednostki mogące obsłużyć równolegne od 128 do 512 wątków co daje im przewagę nad standardowymi CPU których liczba obsługiwanych wątków równolegle jest bardzo ograniczona. Dużą zaletą wykorzystywania GPU w przetwarzaniu danych jest też ich relatywnie niewielkie zapotrzebowanie na energię elektryczną dzięki czemu stały się one podstawą w konstruowaniu klastrów obliczeniowych łączących nieskie koszty eksploatacji z wysoką wydajnością. [15]

Przyszłość badań nad sieciami neuronowymi jawi się obiecująco. Wraz ze wzrostem wydajności obliczeniowej sprzętu do jakiego można uzyskać dostęp naukowcy stopniowo będą zwiększać złożoność sieci neuronowych. Kolejnym naturalnym krokiem po sieciach typu LSTM wydaje się być połączenie ich w wiele współpracujących ze sobą sieci. Pomysł polega na tym, aby w każdej kolejnej iteracji porównać wyniki z wielu sieci które operują na wycinku danych (fragmencie tekstu, wycinku obrazu czy dzwięku). Wówczas jest szansa uzyskać to czego obecne sieci nie potrafią dokonać, a mianowicie zwracanie uwagi na szczegóły [6]. Zasadniczo współczesne sieci neuronowe świetnie radzą sobie z przyswajaniem ogólnych zależności dostępnych w modelu treningowym. W przyszłości być może uda się zmusić je do zwracania większej uwagi na istotne niuanse danych które analizują.

Bibliografia

[1] Justin Johnson. torch-rnn. https://github.com/jcjohnson/torch-rnn, 2016. [Online; dostęp 25-maj-2017].

[2] Nick Bostrom. *Superinteligencja - Scenariusze, strategie, zagrożenia.* Helion, 2014.

[3] Andrej Karpathy. The unreasonable effectiveness of recurrent neural networks. http://karpathy.github.io/2015/05/21/rnn-effectiveness/, 2015. [Online; dostęp 25-maj-2017].

[4] Ryszard Tadeusiewicz. *Sieci neuronowe.* Akademicka Oficyna Wydawnicza, 1991.

[5] Sinh Hoa Nguyen. Sieci neuronowe - uczenie. http://edu.pjwstk.edu.pl/wyklady/nai/scb/wyklad3/w3.htm, 2008. [Online; dostęp 5-czerwiec-2017].

[6] colah's blog. Understanding lstm networks. http://colah.github.io/posts/2015-08-Understanding-LSTMs/, 2015. [Online; dostęp 25-maj-2017].

[7] Jürgen Schmidhuber. Jürgen schmidhuber's page on recurrent neural networks. http://people.idsia.ch/~juergen/rnn.html, 2017. [Online; dostęp 25-maj-2017].

[8] Torch.ch. Proces instalacji torch. http://torch.ch/docs/getting-started.html, 2017. [Online; dostęp 25-maj-2017].

[9] Classic Piano Midi Page. Źródło plików midi z utworami w.a. mozarta. http://www.piano-midi.de/mozart.htm, 2005. [Online; dostęp 5-czerwiec-2017].

[10] Craig Stuart. C++ classes for reading/writing standard midi files. https://github.com/craigsapp/midifile, 2015. [Online; dostęp 5-czerwiec-2017].

[11] Zamzar. Free online file conversion. http://www.zamzar.com/convert/midi-to-mp3/, 2017. [Online; dostęp 5-czerwiec-2017].

[12] Michał Jakóbowski. Profil na platformie streamingowej soundcloud. https://soundcloud.com/micha-jak-bowski, 2017. [Online; dostęp 5-czerwiec-2017].

[13] Nvidia. Obliczenia równoległe z cuda. http://www.nvidia.pl/object/cuda-parallel-computing-pl.html, 2017. [Online; dostęp 25-maj-2017].

[14] Mateusz Górny. Sieci neuronowe oraz technologia cuda. http://student.pwsz.elblag.pl/~stefan/Dydaktyka/2009-2010/SemDyplomowe/Raporty/Gorny/2010-04-12.pdf, 2009. [Online; dostęp 25-maj-2017].

[15] Marcin Marciniak. Computer world news - jak zbudować tani klaster obliczeniowy. http://www.computerworld.pl/news/Jak-zbudowac-tani-klaster-obliczeniowy,364222.html, 2010. [Online; dostęp 12-czerwiec-2017].

Spis tabel

Spis rysunków

Oświadczenie

Ja, niżej podpisany(a) oświadczam, iż przedłożona praca dyplomowa została wykonana przeze mnie samodzielnie, nie narusza praw autorskich, interesów prawnych i materialnych innych osób.

.....	.....
data	podpis